

Терёшин Даниил

Смирнов Александр

Исследование влияния нормализации временных рядов на качество глобальных моделей прогнозирования

Постановка задачи и гипотеза

В multi-series задачах временные ряды часто имеют различные масштабы значений, что может усложнять обучение глобальной модели. Для уменьшения различий между рядами применяется нормализация значений временного ряда. Однако влияние нормализации может зависеть от класса модели. В текущем исследовании хотим проверить влияния способа нормализации на метрики модели

Гипотеза исследования:

Нормализация по рядам важна для глобальных нейронных моделей, но влияет неоднозначно для моделей различных классов:

- для нейронных сетей нормализация может существенно улучшить обучение;
- для моделей на деревьях решений влияние будет слабым;
- для простых бейзлайнов нормализация не окажет заметного эффекта.

Для проверки гипотезы проводится сравнение моделей при различных способах масштабирования данных.

Распределение ролей

Работа выполнялась совместно Терёшиным Даниилом и Смирновым Александром. В рамках эксперимента были реализованы следующие этапы:

- подготовка и обработка данных;
- реализация бейзлайн-моделей;
- обучение глобальных моделей (CatBoost и PatchTST);

- проведение экспериментов с различными вариантами нормализации;
- создание репозитория
- анализ результатов и формулирование выводов.

Описание данных

В эксперименте использовался случайный набор из 200 временных рядов с гранулярностью день из датасета М4. Каждый ряд имеет структуру идентификатора ряда, временной отметки и значение ряда.

Для оценки моделей использовалось разделение на train и test:

- последние 50 наблюдений каждого ряда использовались как тестовый горизонт,
- остальные наблюдения - как обучающая выборка.

Модели должны предсказать 50 будущих значений.

Методология эксперимента

Эксперимент состоял из нескольких этапов.

1. Выбор моделей. Для анализа были выбраны:

- две бейзлайн-модели (SeasonalNaive и Naive),
- две глобальные модели прогнозирования (PatchTST и CatBoost).

2. Масштабирование данных

Для каждого временного ряда применялись различные методы нормализации:

- без нормализации;
- Standard Scaling;
- Robust Scaling;
- Quantile Scaling.

Нормализация выполнялась отдельно для каждого временного ряда, чтобы сохранить структуру данных.

Обучение моделей

Модели обучались на обучающей выборке и затем использовались для прогнозирования тестового горизонта.

Оценка качества

Качество прогнозирования оценивалось по двум метрикам:

1. sMAPE (Относительная ошибка прогнозирования)

Преимущества:

- инвариантность к масштабу,
- устойчивость к различным диапазонам значений.

2. MASE

Нормализованная-метрика, основанная на сравнении с наивным прогнозом:

Интерпретация:

- $MASE < 1$ — модель лучше наивного прогноза,
- $MASE > 1$ — модель хуже.

Использование двух метрик позволяет оценить как относительную, так и масштабированную абсолютную ошибку, в данном случае обе метрики обоснованы

Описание моделей

- Naive. Прогноз равен последнему наблюдаемому значению ряда
- Seasonal Naive. Использует сезонность ряда
- CatBoost. Модель градиентного бустинга по деревьям решений. Для обучения использовались лаговые признаки временного ряда: лаги последних наблюдений (последние 14 дней), лаги, отражающие недельную сезонность
- PatchTST. Нейросетевая модель на основе архитектуры трансформеров, предназначенная для прогнозирования временных рядов. Особенности модели: использование patch-разбиения временного ряда и глобальное обучение на множестве рядов

Результаты эксперимента

Эксперимент показал следующие результаты:

Model	Scaling	sMAPE	MASE
CatBoost	None	0.0558	2.58
CatBoost	Standard	0.4791	2.57
CatBoost	Robust	0.4349	2.58
CatBoost	Quantile	0.5293	3.75
PatchTST	None	0.0543	2.55
PatchTST	Standard	0.4746	2.52
PatchTST	Robust	0.4327	2.52
PatchTST	Quantile	0.5282	3.61
Naive	None	0.0539	2.56
Naive	Standard	0.4799	2.56
Naive	Robust	0.4377	2.56
Naive	Quantile	0.5276	3.62
Seasonal Naive	None	0.0538	2.52
Seasonal Naive	Standard	0.4812	2.52
Seasonal Naive	Robust	0.4474	2.52
Seasonal Naive	Quantile	0.5391	3.58

Анализ результатов

- Бейзлайн-модели практически не изменили качество при применении нормализации. Это объясняется тем, что они используют только значения временного ряда и не обучают параметры модели
- Для модели CatBoost различия между вариантами scaling оказались незначительными. Это соответствует теоретическим ожиданиям: деревья решений являются инвариантными к линейному масштабированию признаков
- Для нейронной модели PatchTST влияние масштабирования оказалось более заметным, однако в данном эксперименте наилучшие результаты были достигнуты без дополнительной нормализации. Это может объясняться тем, что PatchTST уже содержит встроенные механизмы нормализации временных рядов, поэтому дополнительный scaling не всегда улучшает качество.

Выводы

Проведённый эксперимент позволяет сделать следующие выводы.

1. Влияние нормализации действительно зависит от класса модели
2. Бейзлайн-модели практически не реагируют на масштабирование данных
3. CatBoost демонстрирует устойчивость к нормализации благодаря использованию деревьев решений
4. PatchTST может быть чувствителен к нормализации, однако эффект зависит от архитектурных особенностей модели.
5. Дополнительная нормализация не всегда приводит к улучшению качества прогнозирования.

Гипотеза о различном влиянии нормализации на модели разных классов частично подтверждается